WdUM Projekt

Michał Tałałaj

6 stycznia 2026

1 Przygotowanie zbioru danych

Dane wejściowe (*X_train* oraz *X_test*) charakteryzowały się dobrą jakością. Zbiory zawierały po 100 zmiennych objaśniających, wszystkie o charakterze numerycznym. W danych nie występowały brakujące wartości ani wartości nieskończone. Nie zaobserwowano również oczywistych obserwacji odstających. Analiza rozkładów zmiennych wykazała, że większość cech posiadała rozkłady zbliżone do normalnych lub bimodalnych.

Zbiór testowy nie był wykorzystywany na etapie trenowania ani walidacji modeli i został odłożony do końcowej oceny. Zbiór *X_train* został natomiast podzielony na część treningową i walidacyjną w proporcji 0.8/0.2. Podział ten był wykorzystywany wyłącznie na etapie porównywania modeli.

Zmienne objaśniające zostały przeskalowane przy użyciu standaryzacji (*StandardScaler*), dopasowanej na danych treningowych. Następnie scaler został zastosowany do zbioru walidacyjnego.

Zmienna objaśniana (*y_train*) była zbalansowana. Zawierała 745 obserwacji klasy 2 oraz 755 obserwacji klasy 1. W celu uproszczenia dalszej analizy etykiety klasy 2 zostały przekształcone do wartości 0.

2 Trenowanie i walidacja modeli

Pomimo sugestii obecności szumu w danych zawartej w zadaniu nie zastosowano jawnej selekcji zmiennych ani redukcji wymiaru metodą PCA. Decyzja ta wynikała z faktu, że w eksperymencie wykorzystano modele posiadające wbudowane mechanizmy radzenia sobie z nadmiarowymi oraz nieistotnymi cechami, takie jak regularyzacja w modelach liniowych oraz losowy dobór zmiennych w modelach drzewiastych. Dodatkowo, zastosowanie PCA mogłoby utrudnić prowadzić do utraty informacji predykcyjnej w sytuacji, gdy istotny sygnał jest rozproszony pomiędzy wiele oryginalnych zmiennych.

W celu doboru optymalnych hiperparametrów dla każdego z badanych modeli zastosowano Grid Search w połączeniu z 5-krotną walidacją krzyżową. Jako funkcję celu wykorzystano balanced accuracy.

W kolejnych podsekcjach przedstawiono wszystkie modele wytrenowane w projekcie. Dla każdego modelu opisano zastosowaną siatkę hiperparametrów oraz ostatecznie wybrane wartości parametrów, które zostały wykorzystane do predykcji na zbiorze treningowym i testowym. Dla każdego z modeli, gdzie było to możliwe, został zastosowany ten sam random state w celu zapewnienia powtarzalności wyników. Metryki wybranych modeli przedstawiono w tabeli.

Model ElasticNet:

- Parametr regularyzacji C: zakres 10^{-4} – 20, 33 logarytmicznie rozłożone punkty
- Współczynnik proporcji L1/L2 (*l1_ratio*): 0.01 – 0.99, 21 punktów
- Wybrane parametry po Grid Search: $C = 0.0193$, *l1_ratio* $= 0.952$

Model Logistic L1:

- Parametr regularyzacji C: zakres 10^{-3} – 1, 30 logarytmicznie rozłożonych punktów
- Zastosowano karę L1; L2 nie była trenowana ze względu na wyraźną preferencję L1 w Grid Search
- Wybrane parametry po Grid Search: $C = 0.0215$

Model ExtraTrees:

- Liczba drzew (*n_estimators*): 100, 300, 500, 700
- Maksymalna głębokość drzew (*max_depth*): None, 5, 10, 20, 30
- Minimalna liczba próbek do podziału w węźle (*min_samples_split*): 2, 5, 10
- Minimalna liczba próbek w liściu (*min_samples_leaf*): 1, 2, 4
- Liczba cech branych pod uwagę przy podziale (*max_features*): *sqrt*, *log2*, 0.5, 0.8
- Wybrane parametry po Grid Search: *n_estimators*=300, *max_depth*=20, *min_samples_split*=2, *min_samples_leaf*=1, *max_features*=0.8

Model Random Forest:

- Liczba drzew (*n_estimators*): 100, 300, 500
- Maksymalna głębokość drzew (*max_depth*): None, 10, 15, 20
- Minimalna liczba próbek do podziału w węźle (*min_samples_split*): 2, 5, 10
- Minimalna liczba próbek w liściu (*min_samples_leaf*): 1, 2, 4
- Liczba cech branych pod uwagę przy podziale (*max_features*): *sqrt*, *log2*, 0.5
- Wybrane parametry po Grid Search: *n_estimators*=300, *max_depth*=None, *min_samples_split*=2, *min_samples_leaf*=1, *max_features*=0.5

Model XGBoost:

- Liczba drzew (*n_estimators*): 100, 300, 500
- Maksymalna głębokość drzew (*max_depth*): 3, 5, 7, 10
- Współczynnik uczenia (*learning_rate*): 0.01, 0.05, 0.1, 0.2
- Frakcja próbek (*subsample*): 0.6, 0.8, 1.0
- Frakcja cech dla każdego drzewa (*colsample_bytree*): 0.6, 0.8, 1.0
- Minimalne ograniczenie funkcji strat (*gamma*): 0, 0.1, 0.3
- Wybrane parametry po Grid Search: *n_estimators*=300, *max_depth*=10, *learning_rate*=0.1, *subsample*=0.6, *colsample_bytree*=1.0, *gamma*=0.3

Model SVM:

- Parametr regularyzacji C: 0.01 – 100, 10 logarytmicznie rozłożonych punktów
- Typ jądra (*kernel*): *linear*, *rbf*
- Parametr gamma (*gamma*): *scale*, *auto*
- Wybrane parametry po Grid Search: $C = 12.9155$, *kernel* = *rbf*, *gamma* = *scale*

Model Voting Ensemble:

- Skład: 3 najlepiej działające modele drzewiaste – XGBoost, ExtraTrees, Random Forest
- Typ głosowania: *soft*
- Parametry poszczególnych modeli - jak wyżej

2.1 Podsumowanie wyników modeli

Poniższa tabela oraz wykres przedstawiają porównanie najlepszych modeli każdego rodzaju na podstawie balanced accuracy na zbiorze treningowym i testowym oraz różnice między nimi:

Model	Balanced Accuracy (train)	Balanced Accuracy (test)	Overfit Gap
ExtraTrees	1.0000	0.8497	0.1503
Voting Ensemble	1.0000	0.8267	0.1733
Random Forest	1.0000	0.8100	0.1900
XGBoost	1.0000	0.7565	0.2435
SVM	1.0000	0.6933	0.3067
kNN	1.0000	0.6426	0.3574
Logistic L1	0.6143	0.6297	-0.0154
Logistic EN	0.6117	0.6196	-0.0080
GaussianNB	0.6361	0.6168	0.0193

Na poniższym wykresie przedstawiono wykres słupkowy ilustrujący dane z tabeli.

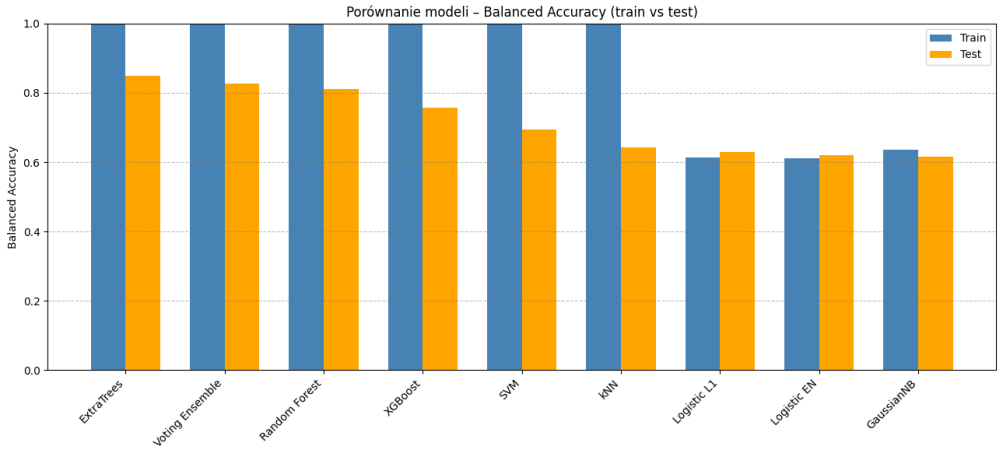

Analiza wyników pokazuje wyraźną tendencję do przeuczenia w większości wytrenowanych modeli, co widać po dużej różnicy między balanced accuracy na zbiorze treningowym a testowym. Wyjątkiem są modele regresyjne oraz Gaussian Naive Bayes, które charakteryzują się niewielkim overfit gap, choć osiągają niższe wartości balanced accuracy na danych testowych. Najlepsze wyniki predykcyjne uzyskały modele drzewiaste takie jak ExtraTrees, Random Forest oraz XGBoost.

3 Ostatecznie wybrany model do predykcji

Do wygenerowania finalnego wektora prawdopodobieństw wykorzystano model ExtraTreesClassifier, wytrenowany na całym zbiorze danych treningowych. Model został skonfigurowany z parametrami najlepszego dopasowania uzyskanymi w Grid Search.

Wybrano ten model ze względu na najwyższą wartość balanced accuracy na zbiorze testowym spośród wszystkich testowanych modeli oraz jego zdolność do selekcji istotnych cech spośród szumu w danych. Model drzewiasty dobrze radził sobie z zachowaniem mocy predykcyjnej przy obecności wielu nieistotnych zmiennych, co czyni go najbardziej odpowiednim do finalnej predykcji.